Rakamin Academy

Project Based Internship

Big Data

Fundamental of Big Data

Daftar Isi

A. Definisi Big Data 3

B. Fungsi Big Data 3

C. Penerapan Big Data 4

D. 5V Big Data 4

E. Distributed File System 7

F. Etika Big Data 12

Glosarium 14

References 15

A. Definisi *Big Data*

Big Data adalah istilah yang digunakan untuk menggambarkan kumpulan data yang sangat besar dan kompleks yang terlalu banyak untuk dianalisis dan diproses menggunakan teknik dan metode tradisional. Istilah ini mencakup berbagai jenis data, termasuk data terstruktur dan tidak terstruktur, serta data yang dihasilkan dari berbagai sumber seperti media sosial, sensor, perangkat seluler, *file log*, dan *server web*.

Big data sendiri merupakan pengembangan dari sistem *database* pada umumnya. Yang membedakan disini adalah proses kecepatan, volume, dan jenis data yang tersedia lebih banyak dan bervariatif daripada DBMS (*Database Management System*) pada umumnya. Penggunaan basis data (*database)* sangat penting dalam pengolahan, penyimpanan serta untuk mengatur segala bentuk informasi secara terstruktur dan tersistem.

B. Fungsi *Big Data*

- *Big data* dapat digunakan untuk memprediksi atau menganalisis penyebab suatu masalah yang terjadi pada sistem. Pemanfaatan dari *big data* ini juga dapat meminimalisir adanya kegagalan. Hasil dari analisis tersebut dapat digunakan dan ditampilkan secara langsung (*real time*).
- *Big data* dapat menjadi referensi untuk mengembangkan sebuah produk. Informasi yang kira-kira dibutuhkan akan disimpan ke dalam *big data* dan hasil dari analisis tersebut dapat menjadi dasar untuk mengambil keputusan yang tepat untuk pengembangan bisnis.

- *Big data* dapat mengurangi waktu dan biaya. Dengan menggunakan *big data* penyimpanan data akan mengurangi biaya yang harus dikeluarkan. Selain itu proses mengirim dan menerima data juga dapat menjadi lebih cepat.

C. Penerapan *Big Data*

Big data sendiri sering diterapkan dan dimanfaatkan oleh para pelaku bisnis. Yang dimana diterapkan dalam penggunaan *sosial media*. Contohnya seperti jumlah komentar, like dan penonton jika postingan dalam bentuk video.

Data aktivitas di *sosial media* seringkali digunakan untuk memutuskan untuk menghadirkan sebuah produk yang dibutuhkan oleh para *customer*. Hal tersebut bisa dijadikan bahan pertimbangan dalam membuat kampanye pemasaran, maupun pertimbangan memasang iklan.

Untuk pengumpulan datanya bisa dilakukan melalui berbagai aktivitas maupun program seperti menganalisis aktivitas penggunaan pada media sosial, seperti *squarelovin*, *crowdfire*, maupun *pixlee* dan masih banyak lagi. Terdapat juga berbagai manfaat yang bisa didapat dari *big data*.

Big data juga sering diterapkan di bidang selain sosial media. Beberapa bidang lainnya seperti yang dilansir oleh Google :

1. Pelacakan kebiasaan berbelanja dan kebiasaan konsumen untuk memberikan rekomendasi produk yang menyesuaikan dengan individu konsumen.
2. Mengawasi pola pembayaran dan menganalisanya terhadap data sebelumnya untuk mendeteksi adanya aktivitas penipuan secara *real-time.*

3. Menggunakan data bersumber dari kamera, sensor dan data GPS untuk mendeteksi jalan berlubang ataupun untuk meningkatkan perawatan jalan di area perkotaan

D. 5V Big Data

5V Big Data memiliki 5 ciri-ciri yang mencerminkan *big data*, yaitu:

1. ***Volume***

   Volume dalam *big data* diartikan sebagai kuantitas atau jumlah data yang dihasilkan dari banyak transaksi serta *volume* data yang disimpan. Contohnya bisa berbentuk *log history* pengguna seperti *history browser,* pencatatan transaksi pada *ecommerce*, data KTP, data pelanggan pada perbankan dan masih banyak lagi. Ukuran *big data* biasanya menggunakan skala *Terabytes* (per 1.000 *Gigabytes*) dan ukuran *Petabytes* (per 1.000.000 *Gigabytes*), pada contohnya berdasarkan publikasi yang dilakukan oleh facebook di https://research.fb.com/blog/2014/10/facebook-s-top-open-data-problems, facebook menghasilkan sejumlah 400 *petabytes* per hari atau 4.00.000.000 *Gigabytes* per hari, tentu data sebesar ini sudah dikategorikan sebagai *big data*.

2. ***Variety***

   Variety ini artinya variasi tipe dan variasi sifat dari data, apakah data tersebut bersifat terstruktur/*structured*, semi terstruktur ataupun tidak terstruktur. Penjelasannya:

   a. **Data terstruktur/ *Structured data*** adalah data yang mempunyai elemen-elemen yang dapat di akses seperti *keys (primary key,*

relational keys, foreign key) untuk dapat dianalisis ataupun data yang disimpan pada format tertentu contohnya data yang berada pada *relational database* ataupun *database SQL.*

b. **Semi Terstruktur/*Semi-structured data*** adalah informasi yang tidak disimpan dalam *relational database* tetapi mempunyai *pattern* atau terorganisir dengan rapi sehingga lebih mudah untuk dianalisa, dengan sedikit pengolahan kita dapat menyimpan data ini ke dalam *relational database* contohnya data pada file XML dan CSV yang sering dipergunakan untuk *export data* pada *database*.

c. **Data Tidak Terstruktur/*Unstructured data*** adalah informasi atau data yang tidak terorganisir dengan baik karena sifat alaminya, atau tidak memiliki *predefined data model* atau model yang sudah terdefinisi contohnya file gambar, suara, vidio, pdf, log files dan lainnya.

3. ***Velocity***

Velocity dalam *big data* artinya adalah kecepatan dalam men-*generate* data, mengakses data serta memproses data. *Big data platform* dan *big data analytics software* tentu harus dapat memproses banyak data secepat mungkin ketika ada *request*, contoh *velocity* salah satunya adalah pada *search engine google*, berdasarkan data pada https://www.internetlivestats.com/google-search-statistics/ google harus memproses rata-rata 40.000 pencarian setiap detiknya.

4. ***Veracity***

Veracity adalah data yang ada dapat dipercaya kebenarannya, dapat diandalkan, berkualitas serta dapat dapat diakses dengan baik. Contoh dari *veracity* dalam bisnis adalah ketika data pelanggan atau data

keluarga perlu dijaga agar tetap akurat, mengingat perubahan yang terjadi seiring waktu, seperti pergantian nomor handphone, alamat, atau status keluarga. Untuk memastikan data tetap akurat, perusahaan seringkali melakukan kegiatan *update data*, yang dengan menghubungi pelanggan untuk memperbarui informasi seperti alamat, nomor *handphone*, dan email. Hal ini penting untuk memastikan analisis data yang akurat dan pengiriman pesan *marketing* yang efektif kepada pelanggan.

5. ***Value***

Value adalah karakteristik terpenting dalam analisis bisnis dalam kerangka *5V big data*. Ini mengacu pada nilai yang dapat ditemukan dalam data dan sangat tergantung pada isi data serta kemampuan tim *data analyst* yang menganalisisnya. Dengan data yang tepat dan analisis yang cermat, *big data* memiliki potensi untuk menghasilkan informasi yang berharga untuk mendukung pengambilan keputusan. Sebagai contoh, dalam konteks Indonesia, pemerintah dapat menggunakan *big data* untuk mengumpulkan informasi dari berbagai kementerian dan instansi, seperti program ketahanan pangan. Dengan data dari berbagai sumber ini, pemerintah dapat menganalisis kapasitas produksi pangan, stok pangan, dan kebutuhan pangan di Indonesia. Dengan analisis data ini, pemerintah dapat memprediksi potensi kekurangan pangan dan mengambil langkah-langkah, seperti meningkatkan kapasitas produksi atau impor pangan, untuk menjaga ketersediaan pangan di dalam negeri.

E. *Distributed File System*

Distributed File System (DFS) adalah sistem *file* yang didistribusikan di beberapa *server file* atau beberapa lokasi. Hal ini memungkinkan program untuk mengakses atau menyimpan *file* terisolasi seperti yang mereka lakukan dengan yang lokal, memungkinkan *programmer* untuk mengakses *file* dari jaringan atau komputer manapun.

Tujuan utama dari *Distributed File System (DFS)* adalah untuk memungkinkan pengguna sistem terdistribusi secara fisik untuk berbagi data dan sumber daya mereka dengan menggunakan *Common File System.* Kumpulan *workstation* dan *mainframe* yang dihubungkan oleh *Local Area Network (LAN)* merupakan konfigurasi pada *Distributed File System.* DFS dijalankan sebagai bagian dari sistem operasi. Di DFS, *namespace* dibuat dan proses ini transparan untuk klien.

DFS memiliki dua komponen:

1. **Transparansi Lokasi**: Transparansi Lokasi dicapai melalui komponen *namespace*.
2. **Redundansi:** Redundansi dilakukan melalui komponen replikasi *file.*

Fitur DFS:

1. **Transparansi**

   Klien tidak perlu mengetahui jumlah atau lokasi server *file* dan perangkat penyimpanan. Beberapa *file* server harus disediakan untuk kinerja, kemampuan beradaptasi, dan ketergantungan.

2. **Transparansi akses**

   File lokal dan jarak jauh harus dapat diakses dengan cara yang sama.

Sistem *file* harus secara otomatis ditempatkan pada *file* yang diakses dan mengirimkannya ke sisi klien.

3. **Transparansi nama *file***

   Seharusnya tidak ada petunjuk dalam nama *file* ke lokasi *file.* Setelah nama diberikan ke *file,* itu tidak boleh diubah selama mentransfer dari satu node ke node lain.

4. **Transparansi replikasi**

   Jika *file* disalin pada beberapa node, salinan *file* dan lokasinya harus disembunyikan dari satu node ke node lainnya.

5. ***Performance***

   Kinerja didasarkan pada jumlah rata-rata waktu yang dibutuhkan untuk meyakinkan permintaan klien. Waktu ini mencakup waktu CPU + waktu yang dibutuhkan untuk mengakses penyimpanan sekunder + waktu akses jaringan. Disarankan agar kinerja Sistem *File* Terdistribusi serupa dengan sistem *file* terpusat.

6. **Ketersediaan**

   Sistem *File* Terdistribusi harus dapat melanjutkan jika terjadi kegagalan sebagian seperti kegagalan tautan, kegagalan *node*, atau *crash drive* penyimpanan. Sistem *file* terdistribusi yang otentik dan mudah beradaptasi harus memiliki *server file* yang berbeda dan independen untuk mengontrol perangkat penyimpanan yang berbeda dan independen.

7. **Skalabilitas**

   Karena menumbuhkan jaringan dengan menambahkan mesin baru atau menggabungkan dua jaringan adalah rutinitas, sistem terdistribusi pasti akan tumbuh seiring waktu. Akibatnya, sistem *file* terdistribusi yang baik

harus dibangun untuk menskalakan dengan cepat seiring dengan bertambahnya jumlah node dan pengguna dalam sistem. Layanan tidak boleh terganggu secara substansial karena jumlah node dan pengguna bertambah.

8. **Integritas data**

   Beberapa pengguna sering berbagi sistem *file.* Integritas data yang disimpan dalam *file* bersama harus dijamin oleh sistem *file.* Artinya, permintaan akses bersamaan dari banyak pengguna yang bersaing untuk akses ke *file* yang sama harus disinkronkan dengan benar menggunakan metode kontrol konkurensi. Transaksi atom adalah mekanisme manajemen konkurensi tingkat tinggi untuk integritas data yang sering ditawarkan kepada pengguna oleh sistem *file*.

9. ***Reliability*/Keandalan**

   Penting untuk meminimalkan risiko kehilangan data dalam sistem *file* terdistribusi yang tepat. Sebagai alternatif membuat salinan cadangan oleh pengguna, sistem *file* seharusnya secara otomatis membuat salinan cadangan dari *file* kunci untuk mengatasi kemungkinan kehilangan data. Banyak sistem *file* mengandalkan penyimpanan yang stabil dengan keandalan tinggi untuk tujuan ini.

10. **Keamanan**

    Sistem *file* terdistribusi harus aman sehingga penggunanya dapat percaya bahwa data mereka akan dijaga kerahasiaannya. Untuk menjaga informasi yang terkandung dalam sistem *file* dari akses yang tidak diinginkan & tidak sah, mekanisme keamanan harus diterapkan.

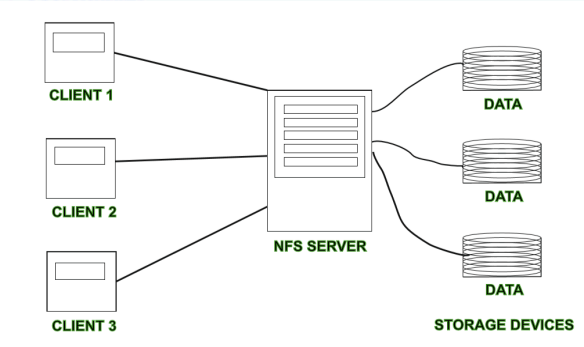

Storage Devices

Keuntungan	Kekurangan
1. DFS memungkinkan banyak pengguna untuk mengakses atau menyimpan data. 2. Memungkinkan data untuk dibagikan dari jarak jauh. 3. Meningkatkan ketersediaan *file*, waktu akses, dan efisiensi jaringan. 4. Peningkatan kapasitas untuk mengubah ukuran data dan juga meningkatkan kemampuan untuk bertukar data. 5. Sistem *File* Terdistribusi memberikan transparansi data bahkan jika server atau disk gagal.	1. Dalam Sistem *File* Terdistribusi, node dan koneksi perlu diamankan oleh karena itu kita dapat mengatakan bahwa keamanan dipertaruhkan. 2. Ada kemungkinan kehilangan pesan dan data dalam jaringan saat berpindah dari satu node ke node lainnya. 3. Koneksi database dalam kasus Sistem *File* Terdistribusi rumit. 4. Juga penanganan database tidak mudah dalam Sistem *File* Terdistribusi dibandingkan dengan sistem pengguna tunggal. 5. Ada kemungkinan overloading akan terjadi jika semua node

Keuntungan	Kekurangan
	mencoba mengirim data sekaligus.

F. Data Ethics (Etika Data)

Etika data dapat diartikan sebagai prinsip-prinsip mengenai bagaimana suatu organisasi mengumpulkan, melindungi dan menggunakan data. Meningkatnya dampak dari data terhadap manusia dan potensi bahaya yang bisa muncul menyebabkan aspek etika data menjadi aspek yang perlu diperhatikan.

4 Hal setidaknya perlu diperhatikan untuk dalam menjaga etika data yaitu transparansi, bertanggung jawab, agen individu dan privasi data.

1. **Transparansi** Transparansi adalah kemampuan untuk mengkomunikasikan secara jelas informasi mengenai data yang akan dikumpulkan, apakah data tersebut akan disimpan, dan siapa saja yang mungkin akan mendapatkannya. Meskipun dokumen syarat dan ketentuan seringkali panjang dan sulit dipahami, pengguna harus memiliki pemahaman yang jelas tentang bagaimana perusahaan akan menggunakan informasi yang mereka berikan. Beberapa contoh penerapan transparansi ini dapat ditemukan di OECD
2. **Akuntabilitas** merujuk pada tanggung jawab suatu organisasi atas apa yang terjadi pada data individu setelah mengumpulkannya. Dari kebocoran data hingga penjualan ke pihak ketiga, perusahaan perlu menerima tanggung jawab atas kerusakan yang dapat ditimbulkan proses mereka kepada pengguna

3. **Agen Individu** Agen mengacu pada kemampuan seseorang untuk membuat pilihan yang bermakna tentang data pribadi mereka. Baik itu kemampuan untuk mengakses, menghapus diri mereka sepenuhnya, atau memilih informasi apa yang harus disimpan, memungkinkan individu untuk mengontrol apa yang terjadi pada informasi mereka harus menjadi hak asasi manusia.
4. **Privasi Data** mengacu pada kemampuan seseorang untuk mengharapkan perlindungan dari eksposur publik data mereka. Jika Anda menyetujui suatu organisasi untuk mengumpulkan data Anda, Anda memiliki ekspektasi yang wajar untuk penyimpanan atau penggunaan berkelanjutan berdasarkan perjanjian awal Anda.

Glosarium

- ***Big Data*** : Sebuah istilah yang merujuk pada volume besar, kecepatan, dan kompleksitas tinggi dari data yang memerlukan teknologi khusus untuk pengelolaan dan analisis.
- ***File Log*** : *File* yang merekam kegiatan atau peristiwa yang terjadi pada suatu sistem atau aplikasi, sering digunakan untuk pemantauan dan analisis.
- ***Server Web*** : Komputer atau perangkat keras yang menyediakan layanan atau konten melalui internet menggunakan protokol HTTP atau HTTPS.
- ***Relational Database*** : Sistem manajemen database (DBMS) yang menggunakan struktur tabel dan kunci relasional untuk menyimpan dan mengelola data.
- **DBMS (*Database Management System*)** : Perangkat lunak yang digunakan untuk membuat, mengelola, dan mengakses database, menyediakan antarmuka untuk pengguna dan aplikasi untuk berinteraksi dengan data.
- ***Real Time*** : Sistem atau proses yang memberikan respons atau hasil dalam waktu nyata atau mendekati waktu kejadian peristiwa.
- ***Squarelovin*** : Platform pihak ketiga yang menyediakan layanan untuk analisis dan manajemen kehadiran dan kinerja di media sosial Instagram.
- ***Crowdfire*** : Platform manajemen media sosial yang membantu pengguna mengelola, memonitor, dan memperluas kehadiran mereka di berbagai platform.
- ***Pixlee*** : Platform pemasaran visual dan manajemen konten yang membantu merek mengumpulkan, mengelola, dan memanfaatkan konten pengguna di media sosial.

- ***Primary Key*** : Kolom atau kombinasi kolom dalam tabel *database* relasional yang secara unik mengidentifikasi setiap baris atau catatan.
- ***Foreign Key*** : Kolom dalam tabel *database* relasional yang menciptakan hubungan dengan kolom di tabel lain, memastikan konsistensi dan integritas referensial.
- ***Common File System in* DFS** : Sistem *file* yang digunakan di *Distributed File System* (DFS) untuk menyediakan mekanisme penyimpanan dan pengelolaan *file* yang didistribusikan di beberapa komputer.

References

Y. Snigdha. *Apa Itu DFS (Sistem File Terdistribusi).* (2023). GeeksforGeeks.What is DFS (Distributed File System)? - GeeksforGeeks

Big Data : Pengertian, Contoh dan Fungsinya. (2023). Universitas Multimedia Nusantara. Big Data: Pengertian, Contoh, dan Fungsinya

Meilinaeka. *Simak Pengertian Big Data Serta Contoh Dari Big Data.* (2023). Universitas Telkom. Simak Pengertian Big Data serta Contoh dari Big Data

What is Big Data. ? (n.d). Google Cloud. Big Data Defined: Examples and Benefits | Google Cloud